

Step 2 · 1주차 제출물

20118701 신재윤

데이터: NinaPro DB2, Exercise 1 (방법 B, 공개 데이터로 축소 구성). 원 논문 데이터와의 차이는 다음과 같다.

- 팔꿈치 각도 조건(30°, 60°)이 없어 8클래스가 아닌 4클래스(open, fist, supination, pronation)로 진행했다.
- 채널은 5개가 아닌 12개다. 1~8번은 전완 돌레에 같은 간격으로, 9번 천지굴근, 10번 총지신근, 11번 상완이두근, 12번 상완삼두근에 부착되어 있다.
- 샘플링 주파수는 1 kHz가 아닌 2 kHz다.
- 시행별 파일이 아니라 피험자별로 약 15분 연속 녹화된 파일이다. 라벨(restimulus)이 바뀌는 지점을 기준으로 시행을 잘라냈고, 앞뒤에 휴식 1초씩을 붙였다.

① 환경 확인

```
(base) mac_mini@shin-mac-miniui-Macmini semg_arm_pred % python - <<'EOF'
heredoc> import numpy, scipy, sklearn, xgboost
heredoc> print('numpy ', numpy.__version__)
heredoc> print('scipy ', scipy.__version__)
heredoc> print('sklearn ', sklearn.__version__)
heredoc> print('xgboost ', xgboost.__version__)
heredoc> EOF
numpy 2.3.5
scipy 1.16.3
sklearn 1.7.2
xgboost 3.1.2
(base) mac_mini@shin-mac-miniui-Macmini semg_arm_pred %
```

② 데이터 요약

표 1. 데이터셋 개요

항목	값
데이터	NinaPro DB2, Exercise 1 (방법 B)
피험자 수	40명
클래스 수	4개 (각도 조건 없음)
총 시행 수	960개
채널 수	12개
샘플링 주파수	2000 Hz
원본 배열 모양 (s1 emg)	(1808331, 12): 15분 연속 녹화의 샘플 수 × 채널
시행 배열 모양	(7813~17379, 12): 샘플 수(시행마다 다름) × 채널

표 2. 클래스별 시행 수와 동작 구간 길이

클래스	DB2 동작 번호	시행 수	피험자 수	피험자당 반복	동작 길이 평균±표준편차 (초)	최소 (초)	최대 (초)
open	5	240	40	6	4.52 ± 1.77	1.94	6.61
fist	6	240	40	6	3.95 ± 1.72	1.94	6.61
supination	9	240	40	6	4.88 ± 1.43	1.91	6.60
pronation	10	240	40	6	4.79 ± 1.59	1.91	6.69

- 4개 클래스 모두 40명 × 6회 = 240시행으로 고르게 들어 있고, 빠진 시행은 없다.
- 시행 길이는 일정하지 않다. 동작 구간이 1.91~6.69초로, 피험자별 평균도 2.6초에서 6.5초까지 차이가 난다. 실험은 동작 5초로 지시했지만, restimulus는 실제로 움직인 구간에 맞춰 라벨을 다시 붙인 것이기 때문으로 보인다.
- DB2 동작 번호(5, 6, 9, 10)와 강의의 4가지 동작의 대응은 공식 동작 목록 그림으로 추가 확인이 필요하다.

③ 신호 그림




그림 1. 피험자 1, fist, 1회차의 12채널 원신호. 빨간 점선은 동작 시작과 끝이다.

- 모든 채널에서 휴식-동작-휴식 3구간이 구분된다. 40명 전체 시행에서 동작 구간의 RMS는 휴식 구간의 약 2.6배 (중앙값)다.
- 채널마다 반응 시점과 크기가 다르다. Ring4와 FDS는 동작 초반에, ED, Ring6, Ring7은 동작 중반에 진폭이 커진다.

④ 비교 관찰

DB2에는 팔꿈치 각도 조건이 없어서, 같은 동작을 30°와 60°에서 비교할 수 없다. 대신 같은 피험자의 4개 동작을 나란히 비교하고(그림 2), 이 관찰이 40명 전체에서도 성립하는지 정규화 RMS로 확인했다(표 3).




그림 2. 피험자 1, 1회차의 4개 동작. 채널별로 y축 범위를 맞췄고, 붉은 배경은 동작 구간이다.

채널	open	fist	supination	pronation
Ring1	0.80	1.45	0.78	0.97
Ring2	0.77	2.03	0.64	0.56
Ring3	1.06	1.46	0.79	0.68
Ring4	1.06	1.11	0.72	1.11
Ring5	0.89	1.02	0.90	1.19
Ring6	0.82	1.32	0.91	0.95
Ring7	0.87	1.52	0.80	0.81
Ring8	1.15	0.95	0.94	0.95
FDS	1.03	1.33	0.71	0.93
ED	1.03	1.34	0.70	0.93
Biceps	0.53	0.45	2.10	0.92
Triceps	0.88	1.15	1.14	0.84
피험자 간 패턴 상관	0.24	0.47	0.71	0.24

표 3. 40명 평균 정규화 RMS. 동작 구간의 채널별 RMS를 피험자·채널마다 4개 동작 평균이 1이 되도록 나눈 값으로, 1보다 크면 그 동작에서 상대적으로 많이 활성화된 것이다. 마지막 행은 같은 동작의 12채널 패턴이 피험자끼리 얼마나 비슷한지를 나타낸 상관계수의 중앙값이다.

- **fist**: 대부분의 채널이 함께 커진다(Ring2 2.03, Ring7 1.52, FDS 1.33, ED 1.34). 손가락을 굽히는 근육과 펴는 근육이 동시에 수축하는 것으로 보인다.
- **supination**: 상완이두근(Biceps) 채널이 2.10으로 가장 뚜렷하고, 피험자 간 패턴도 가장 일관된다(0.71). 상완이두근이 회외에 관여한다는 해부학적 설명과 맞는다.
- **open, pronation**: 두드러진 채널이 없고, 피험자 간 패턴 상관도 0.24로 낮다. 피험자마다 쓰는 근육이 다르다는 뜻이고, 이 두 동작은 피험자를 바꿨을 때 분류가 어려울 수 있다.
- 피험자 1에서는 open 동작의 ED 신호가 거의 없었지만, 40명 평균은 1.03으로 다른 동작과 비슷하다. 피험자 한 명만 보고 판단하면 안 된다는 점을 확인했다.
- 각도와와의 관계: 손동작만 했는데도 상완 채널(Biceps, Triceps)이 동작에 따라 다르게 반응한다. 팔꿈치 각도가 바뀌면 이 채널들의 기본 활성 수준도 바뀔 것으로 예상되지만, DB2로는 검증할 수 없다.

⑤ 클래스 설계안

논문 기준의 8클래스 설계다. 실습에 쓴 DB2에는 각도 조건이 없어서, 실습은 손동작 축만 사용한 4클래스로 진행했다.

1. 클래스 목록

손동작 4종 × 팔꿈치 각도 2종 = 8클래스. 각도는 플레이트로 자세를 고정해 측정한다.

클래스	손동작	각도	정의
30_fist	주먹 쥐기 (Fist)	30°	손가락을 모두 굽힌 상태
60_fist		60°	
30_open	손 펴기 (Open)	30°	손가락을 모두 편 상태
60_open		60°	
30_pronation	회내 (Pronation)	30°	손등이 위로 오도록 전완을 회전
60_pronation		60°	
30_supination	회외 (Supination)	30°	손바닥이 위로 오도록 전완을 회전
60_supination		60°	

2. 채널 대응

채널	측정 근육	기능	부착 위치	DB2 대응 채널
Ch1	요측수근신근 (Extensor Carpi Radialis)	손목 젖힘	전완 후면	없음 (1~8번 전완 돌레 중 일부가 근처)
Ch2	총지신근 (Extensor Digitorum)	손가락 펴	전완 후면	10번
Ch3	천지굴근 (Flexor Digitorum Superficialis)	손가락 굽힘	전완 전면	9번
Ch4	상완이두근 (Biceps Brachii)	팔꿈치 굽힘	상완 전면	11번
Ch5	상완삼두근 (Triceps Brachii)	팔꿈치 펴	상완 후면	12번

3. 설계 근거

기기를 제어하려면 손동작과 팔 자세를 함께 알아야 하는데, 같은 손동작이라도 팔꿈치 각도에 따라 EMG 신호가 달라지므로 두 정보는 서로 독립적이지 않다. 그래서 손동작과 각도 라벨을 조합해 8개 클래스(예: 30_fist)로 만들면, 분류기 하나가 동작과 각도의 조합별 신호 패턴을 직접 학습하고 한 번의 예측으로 두 정보를 동시에 얻을 수 있다.

4. 대안 검토

대안은 동작 분류기(4클래스)와 각도 분류기(2클래스)를 따로 두는 방식이다.

	동시 분류 (8클래스 분류기 1개)	분리 예측 (4클래스 + 2클래스 분류기 2개)
장점	동작과 각도의 상호작용(각도에 따라 동작 신호가 달라지는 것)을 학습할 수 있다. 모델이 하나라 학습과 관리가 단순하다. 두 예측이 서로 모순될 일이 없다.	클래스당 데이터가 많다 (동작 분류기는 각도 2종의 데이터를 합쳐서 쓴다). 각 분류기가 더 쉬운 문제를 푼다. 각도를 늘려도 각도 분류기만 바뀌면 된다.
단점	클래스 수가 곱으로 늘어나 클래스당 데이터가 적다. 동작이 틀리든 각도가 틀리든 똑같이 하나의 오답으로 처리된다.	동작 분류기가 각도에 따른 신호 변화를 잡음으로 받아들이어야 한다. 두 분류기의 오류가 따로 생겨서, 둘 다 맞아야 하는 최종 정확도는 각각보다 낮아진다.

5. 확장 시 문제

- 클래스 수가 곱으로 늘어난다. 각도가 3종이면 $4 \times 3 = 12$ 클래스, 4종이면 16클래스다.
- 클래스마다 같은 수의 시행이 필요하므로 데이터 수집 부담도 비례해서 커진다. 논문 기준(피험자 8명 × 클래스당 30회)이면 각도 4종일 때 3,840개를 모아야 하고, 피험자 한 명이 수행할 시행이 늘어나 피로가 결과에 영향을 줄 수 있다.
- 각도 간격이 좁아지면(예: 45°와 60°) 신호 차이가 작아져서 인접한 각도끼리 헛갈리기 쉽다.
- 각도는 원래 연속값이므로, 종류를 계속 늘리기보다 각도를 회귀로 예측하는 방식이 더 적합해질 수 있다.